

Домашнее задание 3

Important notice

- 1) **К ДЗ №3 можно приступить, не сдав ДЗ №2 полностью.** Если у вас нет данных в DDS-слое DWH, вы можете использовать для сборки ETL сырые данные (напрямую из исходных таблиц). Складывать витрины можно будет не в аналитическую БД, а в отдельную схему на проде.
- 2) **Это задание выполняется и оценивается индивидуально или в группах до 4 человек!** Если вы используете код из открытых источников (репозитории ваших одноклассников таковыми не считаются) - пожалуйста, указывайте ссылки на них (можно в readme вести лог всех источников, откуда вы берете код). Находить готовые рецепты в интернете - хорошо, списывать - плохо.
- 3) **При обнаружении списывания (одинаковый код в двух репозиториях без указания внешнего источника) оценка будет выставляться студенту (группе), чей коммит с решением был первый.** Остальным - 0 баллов и докладная в УО.
- 4) Чтобы исключить возможность списывания, **рекомендуется сделать ваш репозиторий с домашним заданием приватным.**

Формулировка

У нас есть 3 микросервиса, которые работают внутри большого маркетплейса:

- **user_service** - содержит информацию о пользователях
- **order_service** - содержит информацию о заказах пользователей
- **logistics_service** - содержит информацию о том, как заказ разбился на посылки и как они перемещаются по логистической сети (от складов к ПВЗ)

Это мы уже с вами видели в ДЗ №1 и №2.

Сейчас мы имеем:

- * master-хост с БД
- * async-replica, на которую копируются данные для аналитической нагрузки
- * пайплайн доставки данных в аналитическую БД
- * детальный слой DWH в аналитической БД

Задача:

1. **Поднять Apache Airflow в docker-compose.** Идеально - если все приложения будут запускаться одной командой `docker-compose up` (можно притащить нужные сервисы руками, или использовать конструкцию `extends` - <https://docs.docker.com/compose/multiple-compose-files/extends/>)
2. Создайте DAG'и для Airflow, которые используя данные детального слоя DWH собирают следующие витрины:

• Витрина 1: «Аналитика закупок»

- **Описание:** Витрина предназначена для анализа структуры закупок товаров: сколько и каких товаров закупается, кто основные поставщики, динамика цен и объемов закупок. На её основе отдел закупок может оптимизировать процессы, выявить неэффективных поставщиков и прогнозировать будущие потребности.

• Логический состав витрины:

- Дата закупки (по закупке)
- Идентификатор и название товара
- Категория товара
- Поставщик
- Суммарное количество закупленного товара
- Общая стоимость закупки
- Средняя цена закупки по товару и поставщику

• Физический состав витрины:

- ``purchase_date`` (DATE)
- ``product_id`` (INT)
- ``product_name`` (TEXT)

- `category` (TEXT)
 - `supplier\_id` (INT)
 - `supplier\_name` (TEXT)
 - `purchase\_qty` (NUMERIC)
 - `total\_purchase\_amount` (NUMERIC)
 - `avg\_unit\_price` (NUMERIC)
 - **Автоматизировать** процесс обновления витрины с помощью Airflow; Витрина должна полностью обновляться 1 раз в день (в любое время);
 - Витрина должна лежать в схеме **presentation** в вашей аналитической (или продовой) БД
-

• **Витрина 2: «Доставка по складам»**

- **Описание:** Витрина фиксирует дневную картину работы складов и доставки: сколько заказов обработано, среднее время отгрузки, задержки, объёмы распределённые по складам. На витрине удобно анализировать усреднённую и по дням эффективность складской и транспортной логистики.
 - **Логический состав витрины:** собрать витрину, в которой будут следующие данные:
 - Дата (execution_date DAG)
 - Идентификатор склада
 - Общее количество заказов в день по складу
 - Суммарный объём продукции, отгруженный в день
 - Среднее время между созданием заказа и его отгрузкой
 - Количество задержанных заказов (на складе)
 - Количество уникальных заказчиков в день по складу
 - **Физический состав витрины:**
 - `shipment\_date` (DATE)
 - `warehouse\_id` (INT)
 - `warehouse\_name` (TEXT)
 - `order\_count` (INT)
 - `total\_shipment\_qty` (NUMERIC)
 - `avg\_processing\_time\_min` (NUMERIC)
 - `delayed\_orders\_count` (INT)
 - `unique\_customers\_count` (INT)
 - **Автоматизировать** процесс обновления витрины с помощью Airflow; Витрина должна обновлять данные о продажах за business_date на следующий за ним день (каждый день обновляем за вчера). При перезапуске расчета за уже существующий день предыдущие данные должны удаляться, чтобы избежать дублей;
 - Витрина должна лежать в схеме **presentation** в вашей аналитической (или продовой) БД
-

3. Поднять Open Source BI-инструмент по вашему выбору в docker-compose. На семинарах мы с вами рассматривали Metabase, Apache Superset и Grafana, но если привычнее поднять и использовать что-то другое - пожалуйста.

4. Создать аналитический дэшборд по закупкам

- Динамика закупок по месяцам (line chart); Показывает, как меняется общий объём закупок по времени.
- Топ-5 товаров по объёму закупки (bar chart)
- Доли категорий товаров в закупках (pie chart)
- Топ-5 поставщиков по объёму (bar chart)
- Средняя цена закупки по категориям (column chart)

5. Создать аналитический дэшборд по складам

- Количество заказов по складам за день (stacked bar chart)
- Динамика времени отгрузки по складам (line chart)
- Доля задержанных заказов на складе (pie chart)
- Объём отгруженной продукции по складам (column chart)
- Среднее время выполнения заказа по дням (line chart)
- Топ-5 дней с наибольшим количеством уникальных заказчиков (bar chart)

6. Допускаются отступления в реализации (в зависимости от особенностей вышей BI-системы), но смысл всех перечисленных выше элементов должен быть сохранен.

Бонусные задания:

1. Использовать для ETL dbt
2. Бонус за креативность. Красивые визуализации, использование параметризации и т.д.

Сроки

1. Дедлайн на 100% - 2 недели - **21.12.2025 23:59:59 включительно**
2. После **21.12.2025** работы **не принимаются**

Как сдавать ДЗ?

- Так как не все BI-системы позволяют сохранить дэшборд/подключения, вам нужно **записать скринкаст с демонстрацией работы ваших дэшбордов и загрузить его на любой файлообменник, либо отправить мне его сообщением в Telegram**. На вашей системе, скорее всего, есть нативные инструменты для записи видео с экрана (Windows: Win+Shift+S, Mac: cmd+Shift+5), если таких нет - можно воспользоваться записью экрана во время звонка Teams / Zoom / Телемост / Google Meet.
- Готовое ДЗ загружается на GitHub (в приватный репо + выдать мне доступ - @mgcrp)
- Домашнее задание №3 можно продолжать делать в том же репозитории, что и домашнее задание №2 и №1 (можно для связности отвести отдельную ветку)
- К репо должен быть приложен README.md с описанием того, что вы сделали и как это запустить
- Задание сдается в форму: <https://forms.gle/g7zz2B47u5a1xu2c9>

Критерии оценки

Балл	Критерий
4	Поднят AirFlow
3	Реализован ETL для одной из витрин
3	Реализован ETL для обоих из витрин
4	Поднята BI-система
3	Реализован один из двух дэшбордов
3	Реализованы оба дэшборда
+4 балла	Для реализации ETL использован dbt
До 2-х баллов	Бонус за креативность

Максимальный балл за ДЗ - 26

Как это будет проверяться?

- 1) **Запуск системы по инструкции** из вашего README
- 2) **Проверка наличия и работоспособности DAG'ов** в Airflow
- 3) **Проверка наличия и корректности** данных в витринах в CDM-слое аналитической БД
- 4) **Проверка дэшбордов** по записи экрана